

① Gradiente Conjugado  
dem

Examen Final

① Supongamos que  $p_0, \dots, p_m$  son direcciones conjugadas. Expresemos una de esas direcciones,  $p_i$ , como una combinación lineal de las demás:

$$p_i = \sigma_0 p_0 + \dots + \sigma_m p_m$$

para algunos coeficientes  $\sigma_k$  ( $k = 0, \dots, m$ ). Notemos que la suma no incluye a  $p_i$ . Luego, por propiedades de direcciones conjugadas tenemos:

$$\begin{aligned} 0 &= p_0^T A p_i = \sigma_0 p_0^T A p_0 + \dots + \sigma_m p_0^T A p_m \\ &= \sigma_0 p_0^T A p_0 \end{aligned}$$

Lo anterior implica que  $\sigma_0 = 0$  porque los vectores  $p_0, \dots, p_m$  son conjugados y la matriz  $A$  es positiva definida. Se puede usar el mismo argumento para demostrar que los escalares  $\sigma_k$  con  $k = 0, 1, \dots, m$  son cero.

Esto implica que  $p_i = 0$  por la primera ecuación, lo cual contradice que  $p_i$  es un vector no nulo. Por lo que los vectores  $p_0, \dots, p_m$  son linealmente independientes.

① Quasi-Newton  
dem

① Recordemos que uno de las condiciones fuertes de Wolfe es:

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|$$

Lo cual implica que:

$$\begin{aligned} \nabla f(x_k + \alpha_k p_k)^T p_k &\geq -c_2 |\nabla f(x_k)^T p_k| \\ &= -c_2 \nabla f(x_k)^T p_k \end{aligned}$$

porque  $p_k$  es una dirección de descenso. Por lo tanto:

$$\begin{aligned} \nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f(x_k)^T p_k &= (c_2 - 1) \nabla f(x_k)^T p_k \\ &> 0 \end{aligned}$$

Asumiendo que  $c_2 < 1$ , finalmente obtenemos el resultado deseado multiplicando ambos lados por  $\alpha_k$  y observando que  $s_k = \alpha_k p_k$  y  $y_k = \nabla f(x_k + \alpha_k p_k) - \nabla f(x_k)$ .

dem Gradiente Conjugado

② Tenemos que probar que  $B_{k+1} H_{k+1}$  son inversos la uno de lo otro. Basta demostrar que  $B_{k+1} H_{k+1} = I$ . Notemos que  $B_{k+1} s_k = y_k$ . Tenemos que multiplicando  $B_{k+1}$  por la solución  $H_{k+1}$  del BFGS es:

$$\begin{aligned} B_{k+1} H_{k+1} &= B_{k+1} ((I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T) \\ &= (B_{k+1} - \rho_k y_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= \left( B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} \right) H_k (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= \left( I - \frac{B_k s_k s_k^T}{s_k^T B_k s_k} \right) (I - \rho_k y_k s_k^T) + \rho_k y_k s_k^T \\ &= I - \frac{B_k s_k s_k^T}{s_k^T B_k s_k} - \rho_k y_k s_k^T + \frac{B_k s_k s_k^T}{s_k^T B_k s_k} + \rho_k y_k s_k^T \\ &= I \end{aligned}$$

Por esta demostración se usó el hecho que

$$\frac{B_k s_k s_k^T}{s_k^T B_k s_k} = \rho_k \frac{B_k s_k s_k^T}{s_k^T B_k s_k} y_k s_k^T = \frac{1}{s_k^T y_k} \frac{B_k s_k (s_k^T y_k) s_k^T}{s_k^T B_k s_k}$$

② Q. vari Newton

¿Por qué el gradiente conjugado converge en lo más  $n$  iteraciones?

Para checar esto hay que recordar que las direcciones conjugadas  $\{p_i\}$  son linealmente independientes como ya habíamos demostrado. A partir de esto sabemos que generan a todo el espacio  $\mathbb{R}^n$ ; es decir forman una base. Por esto, podemos escribir la diferencia entre  $x_0$  y la sol  $x^*$  como una combinación lineal de nuestras direcciones de la siguiente forma:

$$x^* - x_0 = \sigma_0 p_0 + \dots + \sigma_{n-1} p_{n-1} \quad (1)$$

con  $\sigma_i \in \mathbb{R}$ ,  $i \in \{0, \dots, n-1\}$ . A partir de aquí es importante la propiedad de la conjugación pues multiplicando (1) por  $p_k^T A$  obtenemos

$$\sigma_k = \frac{p_k^T A (x^* - x_0)}{p_k^T A p_k} \quad \text{ye que} \quad p_i^T A p_j = 0 \quad \forall i \neq j$$

!Además  $\alpha_k$  coincide con los términos de paso  $\alpha_k$ ! Y habíamos visto que junto con las direcciones de descenso  $\{p_0, \dots, p_{n-1}\}$  minimizan  $\Phi(\cdot)$  en  $n$  pasos.

¿Cómo es que coinciden?

Pues tenemos que  $x_k = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \dots + \alpha_{k-1} p_{k-1}$  y

multiplicando por  $p_k^T A$ ; tenemos que  $p_k^T A(x_k - x_0) = 0$

$$\therefore p_k^T A(x^* - x_0) = p_k^T A(x^* - x_k) = p_k^T (b - Ax_k) = -p_k^T r_k$$

Esto se puede ver gráficamente también porque las curvas de nivel de  $\Phi$  son elipses si  $A$  es diagonal. Podemos ir minimizando la función al mínimo a través de los ejes.

